



Przetwarzanie języka naturalnego/04

2024-03-21

Krzysztof Misztal

misztal.edu.pl

Spis treści

1 Statystyczne modele języka

2 Markov - szacowanie prawdopodobieństwa

Spis treści

1 Statystyczne modele języka

2 Markov - szacowanie prawdopodobieństwa

Prawdopodobieństwo zdań

- tłumaczenie “mam dobre oceny”:
 $P(\text{"i have \textbf{good} grades"}) > P(\text{"I have \textbf{righteous} grades"})$
- korekcja
 $P(\text{"I'll be late fifteen \textbf{minutes}"}) > P(\text{"I'll be late fifteen \textbf{mints}"})$
- rozpoznawanie mowy
 $P(\text{"I saw rice bowl"}) > P(\text{"eye sour ice bow"})$

Prawdopodobieństwo zdań

- Cel: obliczyć prawdopodobieństwo zdań

$$P(W) = P(w_1, \dots, w_n)$$

- Podobne: prawdopodobieństwa kolejnego słowa

$$P(w_k | w_1, \dots, w_{k-1})$$

- Dowolny z takich rozkładów $P(W)$ lub $P(w_k | w_1, \dots, w_{k-1})$ nazywamy **statystycznym modelem języka**.

Jak to policzyć?

- Cel: policzyć prawdopodobieństwo (joint probability)

$$P(w_1 = \text{My}, w_2 = \text{dog}, w_3 = \text{is}, w_4 = \text{the}, w_5 = \text{best})$$

Jak to policzyć?

- Cel: policzyć prawdopodobieństwo (joint probability)

$$P(w_1 = \text{My}, w_2 = \text{dog}, w_3 = \text{is}, w_4 = \text{the}, w_5 = \text{best})$$

- Intuicja: Polegamy na zasadzie łańcuchowej prawdopodobieństwa (prawdopodobieństwo całkowite)

Jak to policzyć?

- Cel: policzyć prawdopodobieństwo (joint probability)

$$P(w_1 = \text{My}, w_2 = \text{dog}, w_3 = \text{is}, w_4 = \text{the}, w_5 = \text{best})$$

- Intuicja: Polegamy na zasadzie łańcuchowej prawdopodobieństwa (prawdopodobieństwo całkowite)

$$P(A, B, C, D) = P(A)$$

Jak to policzyć?

- Cel: policzyć prawdopodobieństwo (joint probability)

$$P(w_1 = \text{My}, w_2 = \text{dog}, w_3 = \text{is}, w_4 = \text{the}, w_5 = \text{best})$$

- Intuicja: Polegamy na zasadzie łańcuchowej prawdopodobieństwa (prawdopodobieństwo całkowite)

$$P(A, B, C, D) = P(A)P(B|A)$$

Jak to policzyć?

- Cel: policzyć prawdopodobieństwo (joint probability)

$$P(w_1 = \text{My}, w_2 = \text{dog}, w_3 = \text{is}, w_4 = \text{the}, w_5 = \text{best})$$

- Intuicja: Polegamy na zasadzie łańcuchowej prawdopodobieństwa (prawdopodobieństwo całkowite)

$$P(A, B, C, D) = P(A)P(B|A)P(C|A, B)$$

Jak to policzyć?

- Cel: policzyć prawdopodobieństwo (joint probability)

$$P(w_1 = \text{My}, w_2 = \text{dog}, w_3 = \text{is}, w_4 = \text{the}, w_5 = \text{best})$$

- Intuicja: Polegamy na zasadzie łańcuchowej prawdopodobieństwa (prawdopodobieństwo całkowite)

$$P(A, B, C, D) = P(A)P(B|A)P(C|A, B)P(D|A, B, C)$$

Zasada łańcuchowa [NLP]

$$P(w_1, \dots, w_n) = \prod_i P(w_i | w_1, \dots, w_{i-1})$$

Zasada łańcuchowa [NLP]

$$P(w_1, \dots, w_n) = \prod_i P(w_i | w_1, \dots, w_{i-1})$$

$$\begin{aligned} P(\text{"My dog is the best"}) &= \\ &= P(\text{"My"}) \cdot P(\text{"dog"} | \text{"My"}) \cdot P(\text{"is"} | \text{"My dog"}) \cdot \\ &\cdot P(\text{"the"} | \text{"My dog is"}) \cdot P(\text{"best"} | \text{"My dog is the"}) \end{aligned}$$

$$\hat{P}(w_i | w_1, \dots, w_{i-1})$$

Może tak jak w przypadku NB?

$$\frac{\text{count}((w_1, \dots, w_i)) + \alpha}{\text{count}((w_1, \dots, w_{i-1}))}$$

Może tak jak w przypadku NB?

$$\frac{\text{count}((w_1, \dots, w_i)) + \alpha}{\text{count}((w_1, \dots, w_{i-1}))}$$

Złe rozwiązanie - w praktyce prawie zawsze licznik/mianownik będzie równy 0 (α).

Markov property

A stochastic process has the Markov property if the conditional probability distribution of **future** states of the process (conditional on both past and present values) **depends only upon the present** state; that is, given the present, the future does not depend on the past. A process with this property is said to be Markovian or a Markov process.

Założenie o Markowości

$$P(w_1, \dots, w_n) \sim \prod_i P(w_i | w_{i-k}, \dots, w_{i-1})$$

N-gramy

N-gram language model

Model języka złożony z aproksymacji zakładającej własność Markova o $n - 1$ elementach historii nazywamy modelem n -gramowym

N-gramy

- $N = 1 \Rightarrow$ **unigram** model

$$P(w_1, \dots, w_n) \sim \prod_i P(w_i)$$

- $N = 2 \Rightarrow$ **bigram** model

$$P(w_1, \dots, w_n) \sim \prod_i P(w_i | w_{i-1})$$

- $N = 3 \Rightarrow$ **trigram** model

$$P(w_1, \dots, w_n) \sim \prod_i P(w_i | w_{i-2}, w_{i-1})$$

- ...

Model języka?

Dlaczego mówimy, że to prawdopodobieństwo jest modelem języka?

$$P(w_1, \dots, w_n) \sim \prod_i P(w_i)$$

fifth, an, of, futures, the, an, incorporated, a, a,
the, inflation, most, dollars, quarter, in, is, mass
thrift, did, eighty, said, hard, 'm, july, bullish
that, or, limited, the

Model języka?

Dlaczego mówimy, że to prawdopodobieństwo jest modelem języka?

$$P(w_1, \dots, w_n) \sim \prod_i P(w_i | w_{i-1})$$

texaco, rose, one, in, this, issue, is, pursuing,
growth, in, a, boiler, house, said, mr., gurria,
mexico, 's, motion, control, proposal, without,
permission, from, five, hundred, fifty, five, yen

outside, new, car, parking, lot, of, the, agreement,
reached

this, would, be, a, record, november

Jak to się ma do języka?

- Jest to dalekie od wymodelowania pełnej złożoności języka
"My dog which has gone missing after the party is now safe"
- Sprawdza się całkiem dobrze w praktyce

Naive Bayes a modele języka

Naive Bayes jako model języka

Zakładając, że w Naive Bayesie używamy wyłącznie słów jako cech, to buduje on **unigramowy** model języka używanego w każdej z analizowanych klas.

<https://pdos.csail.mit.edu/archive/scigen/>

Spis treści



1 Statystyczne modele języka

2 Markov - szacowanie prawdopodobieństwa

Estymacja prawdopodobieństw

Ponownie, zaczniemy od MLE

$$\hat{P}(w_i|w_{i-1}) = \frac{\text{count}(w_{i-1}, w_i)}{\text{count}(w_{i-1})}$$

Uwaga: W dalszej części skracamy *count* do *c*.

Estymacja prawdopodobieństw – przykład

$$\hat{P}(w_i|w_{i-1}) = \frac{c(w_{i-1}, w_i)}{c(w_{i-1})}$$

I like dogs
dogs like dogs
dogs are like cats

Estymacja prawdopodobieństw – przykład

$$\hat{P}(w_i|w_{i-1}) = \frac{c(w_{i-1}, w_i)}{c(w_{i-1})}$$

@b I like dogs @e

@b dogs like dogs @e

@b dogs are like cats @e

Estymacja prawdopodobieństw – przykład

$$\hat{P}(w_i|w_{i-1}) = \frac{c(w_{i-1}, w_i)}{c(w_{i-1})}$$

@b I like dogs @e

@b dogs like dogs @e

@b dogs are like cats @e

$$\hat{P}(I|@b) = \frac{1}{3}$$

Estymacja prawdopodobieństw – przykład

$$\hat{P}(w_i|w_{i-1}) = \frac{c(w_{i-1}, w_i)}{c(w_{i-1})}$$

@b **I like** dogs @e

@b dogs like dogs @e

@b dogs are like cats @e

$$\hat{P}(I|@b) = \frac{1}{3}, \quad \hat{P}(\textit{like}|I) = \frac{1}{1} = 1$$

Estymacja prawdopodobieństw – przykład

$$\hat{P}(w_i|w_{i-1}) = \frac{c(w_{i-1}, w_i)}{c(w_{i-1})}$$

@b I **like** **dogs** @e

@b dogs like dogs @e

@b dogs are like cats @e

$$\hat{P}(I|@b) = \frac{1}{3}, \hat{P}(\textit{like}|I) = 1, \hat{P}(\textit{dogs}|\textit{like}) = \frac{2}{3}$$

Estymacja prawdopodobieństw – przykład

@b I like dogs @e

@b dogs like dogs @e

@b dogs are like cats @e

$$\hat{P}(I|@b) = \frac{1}{3}, \hat{P}(\text{like}|I) = 1, \hat{P}(\text{dogs}|\text{like}) = \frac{2}{3}$$

$$\hat{P}(\text{cats}|\text{like}) = \frac{1}{3}, \hat{P}(@e|\text{cats}) = \frac{1}{3}$$

$$\begin{aligned}\hat{P}(@b \text{ I like cats } @e) &= \hat{P}(I|@b)\hat{P}(\text{like}|I)\hat{P}(\text{cats}|\text{like})\hat{P}(@e|\text{cats}) = \\ &= \frac{1}{27} \approx 0.037\end{aligned}$$

Do własnego przejrzenia

`https://www.kaggle.com/alvations/
n-gram-language-model-with-nltk`

Dziękuję za uwagę.