



# Przetwarzanie języka naturalnego/05

2023-03-29

Krzysztof Misztal

[misztal.edu.pl](https://misztal.edu.pl)

# Spis treści

---

## 1 Statystyczne modele języka

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
- Viterbi – przykład

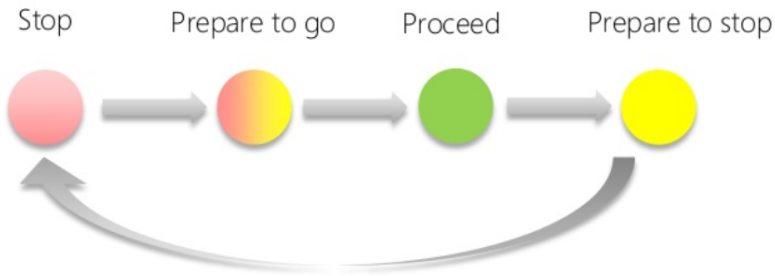
# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
- Viterbi – przykład

# Ukryty Model Markowa

Rozważmy sygnalizację świetlną na skrzyżowaniu



Każdy stan jest zależny od poprzedniego. System jest deterministyczny. Możemy rozważać go jako proces Markowa.

# Process Markowa

---

<https://www.youtube.com/watch?v=EqUfuT3CC8s>

# Process Markowa

- Stan zależy wyłącznie od stanu poprzedniego
- Stan jest niezależny od czasu

- **Proces Markowa** – ciąg zdarzeń, w którym prawdopodobieństwo każdego zdarzenia zależy jedynie od wyniku poprzedniego. W ujęciu matematycznym, procesy Markowa to takie procesy stochastyczne, które spełniają własność Markowa.
- **Łańcuchy Markowa** to procesy Markowa z czasem dyskretnym.
- Łańcuch Markowa jest ciągiem  $X_1, X_2, X_3, \dots$  zmiennych losowych. Dziedzinę tych zmiennych nazywamy przestrzenią stanów, a realizacje  $X_n$  to stany w czasie  $n$ . Jeśli rozkład warunkowy  $X_{n+1}$  jest funkcją wyłącznie zmiennej  $X_n$ :

$$P(X_{n+1} \leq y | X_0, X_1, X_2, \dots, X_n) = P(X_{n+1} \leq y | X_n)$$

to mówimy, że proces stochastyczny **posiada własność Markowa**.



# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
- Viterbi – przykład

# Ukryty Model Markowa

Rozważmy system przewidywania pogody na podstawie obserwacji wodorostów.

# Ukryty Model Markowa

Rozważmy system przewidywania pogody na podstawie obserwacji wodorostów.

- Folklore tells us that "soggy" seaweed means wet weather, while "dry" seaweed means sun.
- If the seaweed is in an intermediate state "damp", then we cannot be sure.


Słownictwo:

soggy - damp - dryish -dry

rozmożony - wilgotny - suchawy - suchy


# Ukryty Model Markowa

Rozważmy model pogodowy




# Ukryty Model Markowa

Rozważmy model pogody



# Ukryty Model Markowa




		Weather today		
		Sunny	Cloudy	Rainy
Weather yesterday	Sunny	0,5	0,2	0,3
	Cloudy	0,1	0,6	0,3
	Rainy	0,2	0,4	0,4

Macierz przejść (transition matrix/state transition matrix)

# Ukryty Model Markowa


## Wprowadzenie procesu Markowa

Observable States



# Ukryty Model Markowa

## Wprowadzenie procesu Markowa



		Seaweed State Today			
		Dry	Dryish	Damp	Soggy
Weather yesterday	Sunny	0,6	0,2	0,15	0,05
	Cloudy	0,25	0,25	0,25	0,25
	Rainy	0,05	0,1	0,35	0,5

Macierz emisji (emission matrix/confusion matrix)



# Ukryty Model Markowa

- Rozkład początkowy  $\pi = [0.63, .017, 0.20]$
- Macierz przejść (transition matrix/state transition matrix)

		<i>Sunny</i>	<i>Cloudy</i>	<i>Rainy</i>
$T =$	<i>Sunny</i>	0,5	0,2	0,3
	<i>Cloudy</i>	0,1	0,6	0,3
	<i>Rainy</i>	0,2	0,4	0,4

- Macierz emisji (emission matrix/confusion matrix)

		<i>Dry</i>	<i>Dryish</i>	<i>Damp</i>	<i>Soggy</i>
$E =$	<i>Sunny</i>	0,6	0,2	0,15	0,05
	<i>Cloudy</i>	0,25	0,25	0,25	0,25
	<i>Rainy</i>	0,05	0,1	0,35	0,5

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
- Viterbi – przykład

# Ukryty Model Markowa

## Ukryty Model Markowa

Trójkę  $(\pi, T, E)$  nazywamy **Ukrytym Modelem Markowa** (Hidden Markov Model, HMM), gdy  $\pi$  jest wektorem rozkładu prawdopodobieństwa rozmiaru  $n$ ,  $T$  jest macierzą  $n \times n$ , której każdy rząd jest wektorem rozkładu prawdopodobieństwa a  $E$  jest macierzą  $n \times m$  o tej samej własności.

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- **Podstawowe zadania HMM**
- Viterbi – przykład

# Podstawowe zadania HMM

- 1 Dla zadanego HMM i zadanego ciągu obserwacji  $(O_1, \dots, O_k)$  oceń jak jest to prawdopodobne zdarzenie
- 2 Dla zadanego HMM i zadanego ciągu obserwacji  $(O_1, \dots, O_k)$  znajdź najbardziej prawdopodobny ciąg stanów ukrytych  $(H_1, \dots, H_k)$
- 3 Dla zbioru obserwacji  $\{(O_1, \dots, O_{k_i})\}_{i=1}^N = 1$  znajdź najbardziej prawdopodobny HMM o określonej strukturze  $(n, m)$
- 4 Dla zadanego zbioru HMM i zadanego ciągu obserwacji  $(O_1, \dots, O_k)$  wskaz najbardziej prawdopodobny HMM

# Spis treści

## 1 Statystyczne modele języka


- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
    - Zadanie 4
    - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - Zadanie 2 - Tagging jako HMM
    - Zadanie 2
    - Zadanie 2 - Viterbi
  - Viterbi – przykład

# Podstawowe zadania HMM

- Dla zadanego HMM i zadanego ciągu obserwacji  $(O_1, \dots, O_k)$  oceń **jak jest to prawdopodobne zdarzenie**

# Podstawowe zadania HMM

Observable States




$$O = (O_1, O_2, O_3) = (dry, damp, soggy)$$

$$P(O|HMM) = ?$$



# Podstawowe zadania HMM



$$O = (O_1, O_2, O_3) = (dry, damp, soggy)$$

$$P(O|HMM) = ?$$

## Podstawowe zadania HMM

$$O = (O_1, O_2, O_3) = (\text{dry}, \text{damp}, \text{soggy})$$

$$\begin{aligned} P(O|HMM) &= P(O|(\text{sunny}, \text{sunny}, \text{sunny})) + \\ &\quad + P(O|(\text{sunny}, \text{sunny}, \text{cloudy})) + \\ &\quad + \dots + \\ &\quad + P(O|(\text{rain}, \text{rain}, \text{rain})) \\ &= \sum_{(H_1, H_2, H_3) \in \{\text{sunny}, \text{cloudy}, \text{rain}\}^3} P(O|(H_1, H_2, H_3)) \end{aligned}$$

# Spis treści


## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - Zadanie 2 - Tagging jako HMM
  - Zadanie 2
  - Zadanie 2 - Viterbi
- Viterbi – przykład

## Podejście naiwne

- Zwraca poprawny wynik
- Wymaga policzenia  $n^{|O|}$  prawdopodobieństw, gdzie  $n$  to liczba stanów ukrytych a  $O$  to ciąg obserwacji, dla naszego przypadku  $3^3 = 27$
- Nie korzysta z własności Markowa

# Forward algorithm




- Rozważmy obliczanie prawdopodobieństw wystąpienia sekwencji stanów zadanych przez HMM

# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - **Zadanie 1 - Forward algorithm**
    - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - Zadanie 2 - Tagging jako HMM
    - Zadanie 2
    - Zadanie 2 - Viterbi
- Viterbi – przykład

## Forward algorithm



$$\alpha_t(x) = P(O_t | H_t = x) P(\text{all paths to } x \text{ before } t)$$

## Forward algorithm

$$\alpha_1(x) = P(O_1|H_1 = x)\pi_x = E_{x,O_1}\pi_x$$

$$\alpha_{t+1}(x) = P(O_{t+1}|H_{t+1} = x) \sum_{i=1}^n \alpha_t(i) T_{i,x} = E_{x,O_{t+1}} \sum_{i=1}^n \alpha_t(i) T_{i,x}$$

$$P(O|HMM) = \sum_{i=1}^n \alpha_{|O|}(i)$$



# Forward algorithm

- 1 Policz  $\alpha_1(x)$  dla każdego stanu ukrytego  $x$ , dla pierwszej obserwacji  $O_1$
- 2 Dla każdej obserwacji  $O_t$  ( $t > 1$ ) i każdego stanu ukrytego  $x$  policz  $\alpha_t(x)$  używając  $\alpha_{t-1}(y)$
- 3 Zwróć sumę  $\alpha_{|O|}(x)$  po wszystkich stanach ukrytych  $x$

# Forward algorithm

- Zwraca poprawny wynik
- Ma złożoność  $|O|n$  (zamiast  $n^{|O|}$ ) (przy ewaluacji od lewej do prawej)
- Korzysta z własności Markowa

# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - Zadanie 2 - Tagging jako HMM
  - Zadanie 2
    - Zadanie 2 - Viterbi
- Viterbi – przykład

# Podstawowe zadania HMM

- Dla zadanego zbioru HMM i zadanego ciągu obserwacji  $(O_1, \dots, O_k)$  wskaz najbardziej prawdopodobny HMM

## Przykład - Pogoda

Założmy, że mamy wymodelowane poszczególne pory roku jako Ukryte Modele Markowa.

Mając dany ciąg obserwacji naszej rośliny z kilku dni - w jaki sposób odpowiedzieć na pytanie "**Jaka mamy porę roku?**"

## Przykład - NLP

Założmy, że mamy wymodelowane wypowiedzi różnych osób jako Ukryte Modele Markowa.

Mając dany ciąg słów (zdanie) - w jaki sposób odpowiedzieć na pytanie "**Kto jest autorem tych słów?**"

# Problem

■ Dane:

$$HMMs = \{HMM_1, \dots, HMM_l\}$$
$$O$$

■ Szukamy:

$$\arg \max_{HMM \in HMMs} P(HMM)P(O|HMM)$$

bo

$$P(HMM|O) = P(O|HMM)P(HMM)\frac{1}{P(O)}$$

W tym konkretnym zastosowaniu - bardzo podobne do Naive Bayesa, tylko poziom abstrakcji wyżej

$$\operatorname{argmax}_{HMM \in HMM_s} P(HMM)P(O|HMM)$$

wygląda analogicznie jak

$$\operatorname{argmax}_{c \in C} P(c)P(d|c)$$



# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - Zadanie 2 - Tagging jako HMM
  - Zadanie 2
  - Zadanie 2 - Viterbi
- Viterbi – przykład

# Podstawowe zadania HMM

- Dla zadanego HMM i zadanego ciągu obserwacji  $(O_1, \dots, O_k)$  znajdź najbardziej prawdopodobny ciąg stanów ukrytych  $(H_1, \dots, H_k)$

# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - **Zadanie 2 - Tagging**
      - Zadanie 2 - Tagging naiwne podejście
      - Zadanie 2 - Tagging jako HMM
    - Zadanie 2
    - Zadanie 2 - Viterbi
- Viterbi – przykład

# Tagging

## Tagowanie tekstu

Mając dany tekst w formie ciągu słów  $d = word_1, \dots, word_k$  oraz ciągu tagów  $t_d = tag_1, \dots, tag_k$  celem tagowania jest zbudowanie funkcji  $f : words \rightarrow tags$ , która dobrze odwzorowuje to tagowanie, tj. minimalizuje jakąś funkcję błędu  $E(f(d), t_d)$ .

# Przykłady

- Wykrywanie czy kropka jest końcem zdania czy użyto jej w innej formie
- Określanie czy dane słowo jest nazwa własna
- **Określanie części mowy**

## Określanie części mowy - Part of speech

- **Noun:** a part of speech inflected for case, signifying a concrete or abstract entity
- **Verb:** a part of speech without case inflection, but inflected for tense, person and number, signifying an activity or process performed or undergone
- **Participle:** a part of speech sharing the features of the verb and the noun
- **Interjection:** a part of speech expressing emotion alone
- **Pronoun:** a part of speech substitutable for a noun and marked for a person
- **Preposition:** a part of speech placed before other words in composition and in syntax
- **Adverb:** a part of speech without inflection, in modification of or in addition to a verb, adjective, clause, sentence, or other adverb

# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - **Zadanie 2 - Tagging naiwne podejście**
    - Zadanie 2 - Tagging jako HMM
  - Zadanie 2
  - Zadanie 2 - Viterbi
- Viterbi – przykład

# Naiwne podejście

Dla danego słowa  $w$

- 1 Jeśli  $w$  nie ma w zbiorze uczącym to zwróć tag, który występuje najczęściej w tym zbiorze
- 2 W przeciwnym razie zwróć tag, który występuje w zbiorze uczącym najczęściej dla słowa  $w$



# Naiwne podejście

---

Jak skuteczne jest tego typu podejście?

# Naiwne podejście

Jak skuteczne jest tego typu podejście?

ok. 90% dla języka angielskiego (dla podstawowej wersji  
V/Adj/N/Det)

# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- **Podstawowe zadania HMM**
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - **Zadanie 2 - Tagging jako HMM**
  - Zadanie 2
    - Zadanie 2 - Viterbi
- Viterbi – przykład

## Założenia:

- Tag (część mowy) słowa  $w_i$  zależy wyłącznie od tagu (części mowy) poprzedniego słowa  $w_{i-1}$
- Tag jest niezależny od czasu
- Słowo jest “generowane” przez swój tag (część mowy), czyli jest zależne tylko od niego

## Od strony matematycznej:

- Założenie Markowa
- Stacjonarność procesu

# POS jako HMM

- Rozwiązujemy problem POS używając HMM:
  - Stany ukryte to możliwe części mowy
  - Stany widzialne (obserwacje) to słowa z języka

# Spis treści


## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - Zadanie 2 - Tagging jako HMM
  - Zadanie 2
    - Zadanie 2 - Viterbi
- Viterbi – przykład

## Podstawowe zadania HMM – wracamy

- Dla zadanego HMM i zadanego ciągu obserwacji  $(O_1, \dots, O_k)$  znajdź najbardziej prawdopodobny ciąg stanów ukrytych  $(H_1, \dots, H_k)$

## Naiwne podejście




$$O = (dry, damp, soggy)$$

$$\arg \max_{(H_1, H_2, H_3) \in H} P(O | H_1, H_2, H_3)$$



# Naiwne podejście



$$O = (dry, damp, soggy)$$

$$\arg \max_{(H_1, H_2, H_3) \in H} P(O|H_1, H_2, H_3)$$

$$= \operatorname{argmax}\{P(O|(sunny, sunny, sunny)), P(O|(sunny, sunny, cloudy)), \\ \dots, P(O|(cloudy, cloudy, cloudy))\}$$

# Naiwne podejście

- Bardzo podobna sytuacja do poprzedniej
- Złożoność wykładnicza ze względu na długość obserwacji
- ... ale zwraca dobry wynik


# Spis treści

## 1 Statystyczne modele języka


- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
  - Zadanie 1
    - Zadanie 1 - Podejście naiwne
    - Zadanie 1 - Forward algorithm
  - Zadanie 4
  - Zadanie 2
    - Zadanie 2 - Tagging
    - Zadanie 2 - Tagging naiwne podejście
    - Zadanie 2 - Tagging jako HMM
  - Zadanie 2
  - Zadanie 2 - Viterbi
- Viterbi – przykład

<https://www.youtube.com/watch?v=6JVqutwtzmo&t=1s>


## Viterbi - podejście trellis



# Viterbi - najbardziej prawdopodobne ścieżki




## Viterbi - najbardziej prawdopodobne ścieżki



$$P_{best,t}(X) = ?$$

## Viterbi - najbardziej prawdopodobne ścieżki




Najlepsza ścieżka do x musi mieć postać:

- ... A X
- ... B X
- ... C X



## Viterbi - najbardziej prawdopodobne ścieżki



Najlepsza ścieżka do x musi mieć postać:

- ... A X      $P_{best,t}(X) = P_{best,t-1}(A)P(A \rightarrow X)P(O_t|X)$
- ... B X      $P_{best,t}(X) = P_{best,t-1}(B)P(B \rightarrow X)P(O_t|X)$
- ... C X      $P_{best,t}(X) = P_{best,t-1}(C)P(C \rightarrow X)P(O_t|X)$

$$P_{best,t}(X) = \max_i P_{best,t-1}(i)P(i \rightarrow X)P(O_t|X)$$

## Viterbi - najbardziej prawdopodobne ścieżki


- $P_{best,t}(X) = \pi_X P(O_1|X)$
- $P_{best,t}(X) = \max_i P_{best,t-1}(i)P(i \rightarrow X)P(O_t|X)$
- $\delta_t(X) = \max_i \delta_{t-1}(i) T_{i,X} E_{X,O_t}$


## Viterbi - najbardziej prawdopodobne ścieżki



Mamy prawdopodobieństwo ścieżki, trzeba ja tylko odzyskać

## Viterbi - najbardziej prawdopodobne ścieżki


$$\delta_t(X) = \max_i \delta_{t-1}(i) T_{i,X} E_{X,O_t}$$


$$\phi_t(x) = \operatorname{argmax}_i \delta_{t-1}(j) P(i \rightarrow x) = \operatorname{argmax}_i \delta_{t-1}(j) T_{i,x}$$

## Viterbi - najbardziej prawdopodobne ścieżki

- Mając dane  $O, HMM$
- Obliczamy  $\delta, \phi$
- Odpowiadamy  $H = (H_{a_1}, \dots, H_{a_{|O|}})$ , gdzie :
  - $a_{|O|+1} := \operatorname{argmax} \delta_{|O|}(i)$
  - $a_t = \phi_{t+1}(a_{t+1})$

# Spis treści

## 1 Statystyczne modele języka

- Wprowadzenie do procesów Markowa
- Wprowadzenie do Ukrytych Model Markowa
- Ukryty Model Markowa
- Podstawowe zadania HMM
- Viterbi – przykład

- **NN** – singular or mass noun
- **VB** – verb, base form
- **TO** – infinitive marker to
- **PPSS** – other nominative personal pronoun (I, we, they, you)

## Części zdania


- **NN** – singular or mass noun
- **VB** – verb, base form
- **TO** – infinitive marker to
- **PPSS** – other nominative personal pronoun (I, we, they, you)

Jakie jest tagowanie dla zdania?

I want to race



# Viterbi



## Viterbi – przykład

- Macierz przejść (transition matrix/state transition matrix)

	VB	TO	NN	PPPS
< s >	.019	.0043	.041	.67
VB	.0038	.035	.047	.0070
TO	.83	0	.00047	0
NN	.0040	.016	.087	.0045
PPPS	.23	.00079	.001	.00014

- Macierz emisji (emission matrix/confusion matrix)

	I	want	to	race
VB	0	.0093	0	.00012
TO	0	0	.99	0
NN	0	.000054	0	.00057
PPSS	.37	0	0	0

# Viterbi

$q_4$	NN	0				
$q_3$	TO	0				
$q_2$	VB	0				
$q_1$	PPSS	0				
$q_0$	start	<b>1.0</b>				
		$\langle s \rangle$	I $w_1$	want $w_2$	to $w_3$	race $w_4$

- Utwórz macierz prawdopodobieństw z kolumną dla każdej obserwacji (np. word token), i jednym wierszem dla każdego stanu (np. POS tag)
- Wypełniamy komórki kolumna po kolumnie
- Wpisz w  $i$ -tą kolumnę oraz  $j$ -ty wiersz prawdopodobieństwo najbardziej prawdopodobnej ścieżki do stanu  $q_j$ , który wyemitował  $w_1, \dots, w_i$

# Viterbi

$q_4$	NN	0	$1.0 \times .041 \times 0$			
$q_3$	TO	0	$1.0 \times .0043 \times 0$			
$q_2$	VB	0	$1.0 \times .19 \times 0$			
$q_1$	PPSS	0	$1.0 \times .67 \times .37$			
$q_0$	start	<b>1.0</b>				
	$\langle s \rangle$	I	want	to	race	
		$w_1$	$w_2$	$w_3$	$w_4$	

- Dla każdego stanu  $q_j$  w czasie  $i$ , wyznacz

$$v_i(j) = \max_{k=1}^n v_{i-1}(k) \cdot a_{kj} \cdot b_j(w_i)$$

- $v_{i-1}(k)$  to poprzednie prawdopodobieństwo ścieżki,  $a_{kj}$  – prawdopodobieństwo przejścia,  $b_j(w_i)$  – prawdopodobieństwo emisji

# Viterbi

$q_4$	NN	0	0	$.025 \times .0012 \times .000054$		
$q_3$	TO	0	0	$.025 \times .00079 \times 0$		
$q_2$	VB	0	0	$.025 \times .23 \times .0093$		
$q_1$	PPSS	0	<b>.025</b>	$.025 \times .00014 \times 0$		
$q_0$	start	<b>1.0</b>				
	$\langle s \rangle$	I	want		to	race
		$w_1$	$w_2$		$w_3$	$w_4$

- Dla każdego stanu  $q_j$  w czasie  $i$ , wyznacz

$$v_i(j) = \max_{k=1}^n v_{i-1}(k) \cdot a_{kj} \cdot b_j(w_i)$$

- $v_{i-1}(k)$  to poprzednie prawdopodobieństwo ścieżki,  $a_{kj}$  – prawdopodobieństwo przejścia,  $b_j(w_i)$  – prawdopodobieństwo emisji

# Viterbi

$q_4$	NN	0	0	.000000002	$.000053 \times .047 \times 0$	
$q_3$	TO	0	0	0	$.000053 \times .035 \times .99$	
$q_2$	VB	0	0	<b>.00053</b>	$.000053 \times .0038 \times 0$	
$q_1$	PPSS	0	<b>.025</b>	0	$.000053 \times .0070 \times 0$	
$q_0$	start	<b>1.0</b>				
	$\langle s \rangle$	I $w_1$	want $w_2$	to $w_3$		race $w_4$

- Dla każdego stanu  $q_j$  w czasie  $i$ , wyznacz

$$v_i(j) = \max_{k=1}^n v_{i-1}(k) \cdot a_{kj} \cdot b_j(w_i)$$

- $v_{i-1}(k)$  to poprzednie prawdopodobieństwo ścieżki,  $a_{kj}$  – prawdopodobieństwo przejścia,  $b_j(w_i)$  – prawdopodobieństwo emisji

# Viterbi

$q_4$	NN	0	0	.000000002	0	.0000018 × .00047 × .00057
$q_3$	TO	0	0	0	<b>.0000018</b>	.0000018 × 0 × 0
$q_2$	VB	0	0	<b>.00053</b>	0	.0000018 × .83 × .00012
$q_1$	PPSS	0	<b>.025</b>	0	0	.0000018 × 0 × 0
$q_0$	start	<b>1.0</b>				
	$\langle s \rangle$	I $w_1$	want $w_2$	to $w_3$	race $w_4$	

- Dla każdego stanu  $q_j$  w czasie  $i$ , wyznacz

$$v_i(j) = \max_{k=1}^n v_{i-1}(k) \cdot a_{kj} \cdot b_j(w_i)$$

- $v_{i-1}(k)$  to poprzednie prawdopodobieństwo ścieżki,  $a_{kj}$  – prawdopodobieństwo przejścia,  $b_j(w_i)$  – prawdopodobieństwo emisji

# Viterbi

$q_4$	NN	0	0	.000000002	0	4.8222e-13
$q_3$	TO	0	0	0	<b>.0000018</b>	0
$q_2$	VB	0	0	<b>.00053</b>	0	<b>1.7928e-10</b>
$q_1$	PPSS	0	<b>.025</b>	0	0	0
$q_0$	start	<b>1.0</b>				
	$\langle s \rangle$	I $w_1$	want $w_2$	to $w_3$	race $w_4$	

- Dla każdego stanu  $q_j$  w czasie  $i$ , wyznacz

$$v_i(j) = \max_{k=1}^n v_{i-1}(k) \cdot a_{kj} \cdot b_j(w_i)$$

- $v_{i-1}(k)$  to poprzednie prawdopodobieństwo ścieżki,  $a_{kj}$  – prawdopodobieństwo przejścia,  $b_j(w_i)$  – prawdopodobieństwo emisji



## Viterbi – przykład 2

Jakie jest tagowanie dla zdania?

deal talks fail

- Macierz przejść (transition matrix/state transition matrix)

	to N	to V
from start	.8	.2
from N	.4	.6
from V	.8	.2

- Macierz emisji (emission matrix/confusion matrix)

	deal	fail	talks
N	.2	.05	.2
V	.3	.3	.3

# Viterbi

	deal	talks	fail
N	$.8 \times .2 = .16$	$\leftarrow .16 \times .4 \times .2 = .0128$ (bo $.16 \times .4 > .06 \times .8$ )	$\swarrow .0288 \times .8 \times .05 = .001152$ (bo $.0128 \times .4 < .0288 \times .8$ )
V	$.2 \times .3 = .06$	$\swarrow .16 \times .6 \times .3 = .0288$ (bo $.16 \times .6 > .06 \times .2$ )	$\swarrow .0128 \times .6 \times .3 = .002304$ (bo $.0128 \times .6 > .0288 \times .2$ )

**Dziękuję za uwagę.**